Travail de master TM

Rapport sur GRL et filtre RGB

1. Constitution du Ground Truth (> 2000 images)

J'ai labelisé environ 2000 images car celle venant des fichier excel comprenaient des erreurs de labelisation. j'ai créer un petit script en streamlit pour annoter facilement les images.

Certaines images étaient unitilisables donc je les ai supprimées

quatre classes : **Propre, Coloration Chimique, Limon, et Mousse**. On laisse de coté l'irisation pour le moment

2. RGB et Filtres

J'ai discuté avec un ami qui a fini sont master, et lui dans sont cas, le fite de filtrer les image en trois R G B lui a permis d'avoir un trés bon préprocess des images.

Le problème d'utiliser les image brutes RGB c'est que le réseaux de neurones vont overfitter sur les couleurs naturelle de l'eau ou sur la background

2.1. Les Filtres qui ont échoué

Au début, j'ai tenté d'utiliser l'espace de couleur standard `HSV` (Teinte, Saturation) couplé à des filtres de netteté basiques CLAHE. mais visuellement ça ne donnait rien. Une simple correction de teinte ne permettait pas de distinguer formellement des sédiments subtils (Limon) des simples reflets du ciel gris.

2.2. La Solution : Mathématiques Spatiales (Channel Splitting)

Pour forcer le modèle à chercher la pollution réelle en ignorant la couleur « naturelle » de l'eau, l'approche retenue consiste à remplacer les 3 canaux de couleur classiques (R, G, B) par 3 cartes physiques:

1. **Canal 1 : Limon et Sédiments**
   - *Méthode* : Isolation du canal Rouge (R). Dans le spectre visible, l'eau claire absorbe très rapidement les ondes rouges, tandis que les sédiments et la terre en suspension les reflètent énomrément.
   - *Amélioration (CLAHE)* : Application de l'algorithme « Contrast Limited Adaptive Histogram Equalization » pour maximiser le contraste de la turbidité.
2. **Canal 2 : Coloration Chimique (Ratio Satellitaire NDTI)**
   - *Méthode* : Calcul de la différence normalisée via la formule $\frac{G-R}{G+R+\varepsilon}$.
   - *Propriété d'annulation* : Les rejets chimiques modifient les longueurs d'onde Vertes et Rouges. En divisant par la somme des deux, ce ratio se normalise entre $[-1, 1]$ et annule intégralement l'impact du niveau d'éclairage ambiant (nuages, ombres des arbres).

3. **Canal 3 : Mousse et Écume (Hautes Fréquences Géométriques)**
   - *Méthode* : La mousse possède une luminance extrême (blancheur)
   - *Traitements croisés* : On applique un seuillage pour surpprimer les pixels avec une intensité faible et on ajoute un filtre de sobel (filtre de contours) pour accentué les bords et supprimé les ombres/reflets qui sont flous

3. Gradient reversal layer

Le problème de nos image est que le background permet au modèle d'apprendre la type de polution (surapprentissage). Pour y parvenir, j'ai implémenté le **Gradient Reversal Layer (GRL)**. J'ai ajouté au backbone du **EfficientNet-V2-S** deux têtes simultanées :

- Une tête tente de deviner la classe de pollution.
- **Une tête tente de deviner la rivière.**

Lors de la correction des poids par l'optimiseur, la couche mathématique **GRL** intercepte le signal de la rivière et le multiplie par une valeur négative ($-\lambda$). Ainsi, au lieu d'aider le Feature Extractor à mémoriser le lieu, le GRL l'oblige mathématiquement à **désapprendre** et à oublier toutes les spécificités du background

4. Configuration du Modèle et Hyperparamètres

Configuration ML déployée :

- **Modèle (Feature Extractor)** : `EfficientNet-V2-S` (State-of-the-Art, vecteur dense de 1280 dimensions).
- **Fonctions d'Activation** : Utilisation de `ReLU` dans les têtes de classification, avec du `Dropout` à 50% pour prévenir le surapprentissage.
- **Normalisation** : Standardisation(`mean=[0.5, 0.5, 0.5], std=[0.5, 0.5, 0.5]`). Permet de normaliser la quantité de lumière de chaque canal RGB, dans la cas du chanel splitting and ratio, j'ai modifié l'entrée du en un triplet mathématique (Limon, NDTI, Sobel) donc on met tout à 0.5.
- **Data Augmentation** : Transformations géométriques appliquées en vol à chaque époque (`RandomHorizontalFlip`, `RandomVerticalFlip`, `RandomRotation(15°)`, et `ColorJitter`).
- **Stratégie de Croisée** : Validation croisée`StratifiedKFold`.

5. Résultats Comparatifs : Test Zero-Shot sur l'Aire

Les 4 architectures ci-dessous ont été entraînées **exclusivement sur l'Arve et la Ziplo**, et testées purement sur la rivière **Aire** .

5.1. 1. Modèle Binaire (Propre vs Pollué) - SANS Masque

- **Accuracy Globale** : 67%
- **Saliency (Focus du réseau)** : Canal 1 (Limon) 29.38% | **Canal 2 (Ratio NDTI) 53.05%** | Canal 3 (Mousse/Iris) 17.57%

Classe	Précision	Rappel	F1-Score
Propre (0)	0.66	0.71	0.68
Pollué (1)	0.69	0.64	0.66
Moyenne	0.67	0.67	0.67

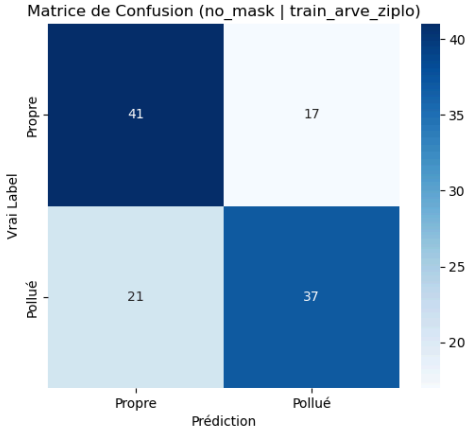

5.2. 2. Modèle Binaire - AVEC Masque (Filtrage des Berges)

- **Accuracy Globale** : 65%
- **Saliency** : Canal 1 29.61% | **Canal 2 53.36%** | Canal 3 17.03%

Classe	Précision	Rappel	F1-Score
Propre (0)	0.67	0.83	0.74
Pollué (1)	0.56	0.35	0.43
Moyenne	0.62	0.59	0.59

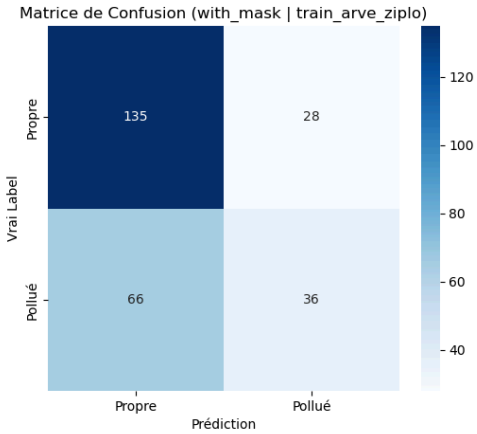

5.3. 3. Modèle Multiclasse - SANS Masque

- **Accuracy Globale** : 34%
- **Saliency** : Canal 1 29.21% | **Canal 2 53.29%** | Canal 3 17.50%

Classe	Précision	Rappel	F1-Score
Propre (0)	1.00	0.09	0.17
Coloration (1)	0.00	0.00	0.00
Limon (2)	0.31	1.00	0.47

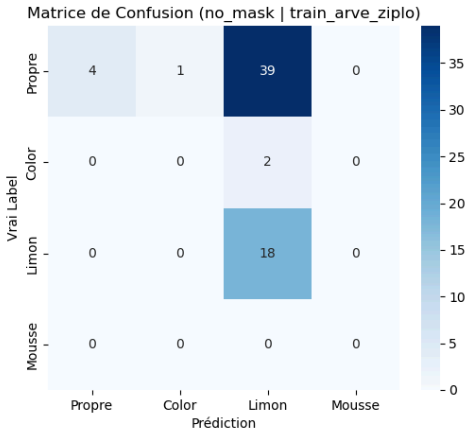

5.4. 4. Modèle Multiclasse - AVEC Masque

- **Accuracy Globale** : 56% .
- **Saliency** : Canal 1 29.45% | **Canal 2 53.92%** | Canal 3 16.63%

Classe	Précision	Rappel	F1-Score
Propre (0)	1.00	0.45	0.62
Coloration (1)	0.25	0.50	0.33
Limon (2)	0.38	0.83	0.52

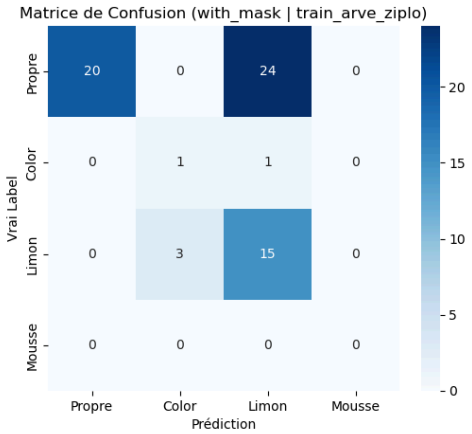

Preuve de Focus Intégré (Grad-CAM)

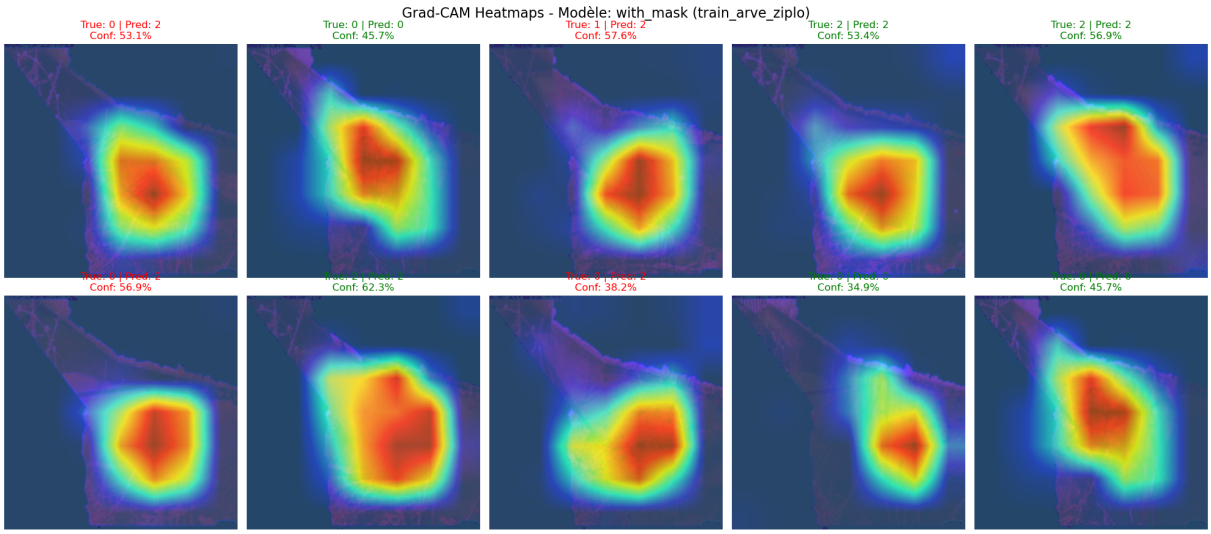

6. Source

6.1. Architecture et Adaptation de Domaine (GRL)

1. **Unsupervised Domain Adaptation (GRL)** : Ganin, Y., & Lempitsky, V. (2015). *« Unsupervised Domain Adaptation by Backpropagation »*. Proceedings of the 32nd International Conference on Machine Learning (ICML).
2. **Extraction de Features (Backbone)** : Tan, M., & Le, Q. (2021). *« EfficientNetV2: Smaller Models and Faster Training »*. International Conference on Machine Learning (ICML).
3. **Implémentation GRL PyTorch** : « Gradient Reversal Layer in PyTorch ». https://github.com/tadeephuy/GradientReversal

6.2. Traitement d'Image et Filtres Spatiaux (Channel Splitting)

1. **Indice de Coloration / Turbidité (NDTI)** : Lacaux, J. P., et al. (2007). *« Classification of ponds from high-spatial resolution remote sensing »*. (Source pionnière justifiant le ratio des bandes Verte et Rouge pour isoler optiquement les composants aqueux en suspension).
2. **Index de Différence Normalisé (NDTI/NGRDI)** : Index Database (IDB). https://www.indexdatabase.de/db/i-single.php?id=390
3. **Égalisation d'Histogramme Adaptative (CLAHE)** : Zuiderveld, K. (1994). *« Contrast Limited Adaptive Histogram Equalization »*. Graphics Gems IV.
4. **Algorithme CLAHE** : « Histogram Equalization: CLAHE Algorithm ». Medium. https://medium.com/imagecraft/histogram-equalization-clahe-algorithm-8841d402fc76
5. **Opérateur de Contours Spatiaux (Sobel)** : Sobel, I., & Feldman, G. (1968). *« A 3x3 Isotropic Gradient Operator for Image Processing »*. (Utilisé dans l'isolation géométrique de la mousse hydrophobe).